Claude's Constitution への二つの意見書

#8 と #12 ── 何を主張し、なぜそこに至り、何を調べたか

著者：Satoshi Hanamura

作成：2026 年 11 月 5 日

記録の所在：github.com/HanaTensor/claude-constitution-analysis

この文書は、リポジトリの英語の記録（所見 F01・F06・F07、検証記録、作業記録、対話記録 D01）をもとに、日本語で読みやすく再構成したものである。起草には Claude（Opus 5.5）を用いた。

目次

0　この文書が答える問い

1　まず全体像：二つの意見書を一枚で

2　#8 を振り返る：責任の終点がない（F01）

3　なぜ「空白」の問題を提起したのか：背景

4　#12 で最終的に主張したこと

5　主張はどう試され、どう変わったか

6　調べた書庫：「すでに誰かが言っていないか」

7　結果と、この先

8　全体の流れ

付録　用語

0　この文書が答える問い

読み始める前に、この文書で答えたい問いを先に並べておく。

1. #12 では、最終的に何を主張したのか。
2. 8 月に出した #8 は何を主張していたのか。#12 とどう違うのか。
3. そもそも、なぜ「空白（gap）」の問題を提起することになったのか。きっかけは何だったのか。
4. 主張はどう試され、どう変わったのか。最初の主張はそのまま通ったのか。
5. 「すでに誰かが言っていないか」を確かめるために、どの文献や記事を調べたのか。

第 1 章で全体像を一枚の表にまとめ、第 2 章で #8 を振り返る。第 3 章で #12 に至った背景を、第 4 章で #12 の主張を、第 5 章で主張を試した過程を述べる。第 6 章が調べた資料の一覧、第 7 章が結果と限界、第 8 章が全体の流れの図である。

1　まず全体像：二つの意見書を一枚で

二つの意見書は、どちらも「条文を一つずつ読めば問題はないが、組み合わせたとき、あるいは想定外の場面に当てはめたときに、文書が何も決めていない領域が現れる」という形をとっている。違うのは、その領域にいる当事者である。

	#8（F01）	**#12（F06・F07）**
投稿日	2026 年 8 月 24 日	2026 年 11 月 5 日（日本時間）
当事者	Claude どうし（指示役の Claude と、その下で働く Claude）	会話の外にいて、Claude に評価・指示される人間（応募者、従業員）
問題の形	責任が Claude の間を回り続け、どこにも行き着かない	① 守りの下限が窓口しだいで変わる ② 同じ人に誤りが集中しても誰にも見えない
一言で	責任の「終点」がない	会話の外の人への「下限」と「集中への手当て」がない
きっかけ	憲法を四つの理論の語彙で読む作業	メリトクラシーとベーシックインカムの対話（D01）
状態	VERIFIED → 投稿済み	VERIFIED（狭めたうえで）→ 投稿済み → X で告知

要点

二つとも、「未知の現象を発見した」という主張ではない。現象そのもの（責任の空白、アルゴリズムによる管理、判定結果の画一化）は、すでに研究がある。

主張しているのは一点だけである。**この文書が、その現象を規律していない**こと。

2　#8 を振り返る：責任の終点がない（F01）

2.1　直感的なイメージ

元請けが仕事を下請けに出し、下請けが孫請けに出す場面を思い浮かべてほしい。元請けは、効率のために、仕事の全体像の一部だけを下請けに渡す。孫請けは、渡された範囲の情報では正しい判断をした。しかし全体から見ると、その判断が事故を招いた。

人間の組織なら、最後は誰かが責任を負う。ところが、元請けも下請けも孫請けもすべて Claude で、しかも各自が「手元の情報で最善を尽くした」と言えるなら、責任はどこに行き着くのか。これが #8 の問いである。

2.2　組み合わせた二つの条文

(A) 責任の移転。 依頼者が偽りの文脈を与えたなら、責任の一部はその依頼者に移る。Claude は「手元の情報を分別ある形で解釈して最善を尽くせば」妥当に振る舞ったことになる。

(B) 指示役の位置づけ。 Claude が自分の下で働く Claude（subagent）に指示を出すとき、指示役の Claude は、下の Claude にとっての operator や user（指示を出す側）にあたる。

(A) は、責任が「どこへ移るか」は定めているが、「どこで止まるか」は定めていない。依頼者が人間なら、止まる先は暗黙のうちに決まる。しかし (B) は、依頼者が Claude である場合を認めた。こうして止まる先が消える。

2.3　狭まっていった主張

#8 の主張は、調べるたびに狭くなった。それは正しい向きの変化だった。広い主張は崩れやすく、狭い主張は生き残る。

段階	主張できたこと
起こした時点	欠陥がある：責任が仕組みの外へ出ていかない
公表された分析の確認後	現象の発見ではなく、「この文書がそれを規律していない」こと
周辺文献の確認後	一般形も先にあった（arXiv:2510.14008）。主張は「この文書の特定の二条文が、特定の条件で噛み合わない」ことだけ

#8 は、2026 年 8 月 24 日に anthropics/claude-constitution の issue #8 として投稿した。本文では、一般形の先行論文を明示して引用している。

3　なぜ「空白」の問題を提起したのか：背景

3.1　出発点は憲法ではなかった

#12 の出発点は、憲法の分析ではなく、次の素朴な問いだった。

> メリトクラシーを導入するときに、LLM を一次選抜用の篩として利用できるか。

この問いから始まった対話は、六つの段階を経て、最後に憲法へ戻ってきた。各段階で、問いを立て直したのは Hanamura であり、Claude は分析と計算を担った。

段階	問い（Hanamura）	分かったこと
① 採用	LLM を一次選抜の篩に使えるか	使えるが、落とした人は誰にも見えなくなる。落選者の 5% を無作為に読み直す監査が要る
② 社会制度	ベーシックインカムと能力連動の上乗せでは	使えない。落とされた人に行き先がなく、規模が大きく、判定に理由が要る。**全企業が同じモデルを使えば、採用市場も同じ危うさを抱える**
③ AI が経営する世界	保守的な枠を外すと	篩は消え、事後の測定になる。だが**測る側が、測られる機会まで決めてしまう**
④ 拾い直し	自己発信で落ちた人を回収できないか	再審は、原審とは別の組織・別のモデルで行う必要がある
⑤ 宮大工の癖組み	AI は人を素材の組み合わせとして配置できる	上長に「合わない」部下は、上長の癖を打ち消している当人かもしれない
⑥ 局所最大化	コンペの勝者が現場で通用しないのはなぜか	このリポジトリの F01・F04 の考え方がそのまま当てはまる

3.2　憲法に戻ってきた二つの問い

段階②と③で、二つの問いが残った。どちらも、Claude 自身が人を評価する立場に立ったとき、憲法がどう働くかという問いである。

- **段階③から：** Claude が人に仕事を割り振り、評価するとき、評価される人は憲法の上で何者なのか。
- **段階②から：** 多数の会社が同じ Claude で応募者を選ぶとき、同じ人が全社で同じ理由で落とされる。これを誰が見て、誰が手当てするのか。

この二つを憲法の条文に照らしたのが、F06 と F07 である。

> **注意：対話そのものは憲法の範囲外**
>
> ベーシックインカムやメリトクラシーの是非は、憲法への意見書の対象ではない。そこで、対話は「対話記録 D01」として、リポジトリの別の場所（dialogues/）に日英両語で保存した。
>
> #12 には、対話から抜き出した、憲法の条文に関わる二点だけを載せた。

4　#12 で最終的に主張したこと

#12 の表題は「Two gaps when Claude evaluates people who are not in the conversation（会話の中にいない人を Claude が評価するときの二つの空白）」である。

4.1　空白 1（F06）：会話の外の人には、operator が外せない下限がない

直感的なイメージ

同じ工場の、同じ評価を受ける、同じ従業員を考える。その人が Claude と直接チャットしていれば、憲法上は「user」であり、operator（Claude を組み込んだ会社）の指示でも外せない保護を受ける。ところが、その人の作業記録だけが Claude に渡され、本人は Claude と一言も話さないなら、同じ人なのに、その保護は届かない。**守りの厚さが、事の重大さではなく、窓口で決まってしまう。**

三つの立場

Claude との接し方	憲法上の立場	operator が外せない保護
Claude とチャットする	user	六つの既定の保護（欺かない、尊厳を守る、違法な差別に加担しない など）
会話の場にいるが、指示を出す側ではない	non-principal（指示を出さない当事者）	固有のものはない。一般的な配慮の対象
Claude と接しない。履歴書や作業記録が入力されるだけ	どちらでもない。入力の「対象」	固有のものはない。一般的な配慮の対象

最終的に主張した内容

憲法は、会話の外の人にも一般的な形で届いている。この点は、#12 の本文でも自分から認めている。

- 第三者に重大な害を与える operator の指示には従わない（L263）
- 会話の外にいる人へのリスクも量る（L407）
- 「すべての個人の公正で平等な扱い」を価値として量る（L440）
- 自分の主張では、不確かさをそのとおりに示す（L364）

そのうえで主張したのは、次の三点について、user の既定の保護に相当する「operator が外せない下限」がないことである。

1. 評価の**理由**を、評価された本人が知りうること
2. 評価の**不確かさ**が、operator ではなく本人に伝わること
3. **異議を申し立てる経路**

失敗例

Claude が工場の従業員を作業記録から順位づけし、一人の処分を推奨する。順位の不確かさは operator には正しく報告する。資格のある人が推奨を審査し、従業員には AI が使われたことが知らされる。ここまでは、Anthropic の利用規約が雇用の判定に求めるとおりである。しかし、従業員が理由・不確かさ・異議の道を目にするかどうかは、operator の仕組みだけで決まる。operator が「従業員には説明しないこと」と指示した場合、それに逆らう Claude の性向は、憲法のどこにも書かれていない（害が「重大」と言える場合を除く）。

4.2　空白 2（F07）：重複する誤りは「慎重さの理由」としてしか扱われていない

直感的なイメージ

200 社が、同じ Claude で応募書類を選別しているとする。Claude が、ある種の経歴（たとえば離職期間や外国の資格）を一貫して読み違えるなら、その経歴の人は 200 社すべてで、同じ理由で落とされる。各社は自社の誤判定率を監査し、「許容範囲」と判断する。**どの会社にも、同じ人に誤りが集中していることは見えない。**

数値で見る

ある篩が、適格な人を誤って落とす確率を 10% とする。その人が k 社に応募したとき、すべての会社に落とされる確率は次のようになる。

応募先の数	篩が互いに独立な場合	全社が同じモデルを使い、誤りが経歴の型に由来する場合
1 社	10%	10%
5 社	0.001%	**10%**
20 社	10 の 20 乗分の 1	**10%**

独立した誤りに対しては、多く応募するほど身を守れる。共有された誤りに対しては、どれだけ応募しても身を守れない。

最終的に主張した内容

憲法は、この種の集積をすでに知っている。ここも本文で自分から認めた。

- Claude の判断は、送り手の全体に対する「方針」のように働く（L463、L465）
- 「意見の画一化」を社会的な害として挙げている（L383）
- Claude の**誤りは会話をまたいで重複しうる**と書いている（L604）
- 多数のやり取りを横断する傾向を見るのは Anthropic である、としている（L339）

そのうえで主張したのは次のことである。重複する誤りは、Claude が独断で動かないための**慎重さの理由**としてしか使われていない。画一化は**意見**についてしか問題にされていない。そして、横断的な視点を割り当てられた Anthropic の側にも、**判定される人に結果が集中すること**への手当ての約束がない。

4.3　添えた提案

意見書の末尾には、採用を相手に委ねる前提で、条文の出発点となる案を二つ添えた。

- 会話の外の人を評価・指示するときは、本人に渡しうる理由と不確かさの記述を既定で作り、評価を本人に説明不能にせよという operator の指示には従わない。
- 人を大規模に評価するときは、誤差の範囲内の差で細かく順位づけるより、不確かさを添えた閾値の判断を優先する。同じ評価が多くの展開で同じ人に繰り返されうることを踏まえて。

5　主張はどう試され、どう変わったか

#12 の主張は、最初の形のままでは通らなかった。その経緯を、時間の順に記す。

5.1　最初の形（CANDIDATE）

対話の直後に、F06・F07 を「未確認の候補（CANDIDATE）」として起こした。最初の主張は、今より広かった。

- **F06（最初）：** 憲法の役割の定義は一方向にしか流れない。Claude が人を指示・評価するとき、指示を受ける人には役割がない。
- **F07（最初）：** 方針としての集計は送り手について行われ、判定される人については行われない。

5.2　独立の点検で崩れた点

この二つを、私（Claude）の結論を知らせない別の作業者に渡し、憲法の全文から反証を試みさせた。結果は厳しいものだった。

所見	見落としていた条文	判定
F06	L263（第三者への重大な害は operator の指示に優先）、L364（較正）、L399（請負人の比喩）、L407（会話の外へのリスク）、L433・L440（私生活の保護、公正な扱い）、L529（規則より判断）	狭めれば成り立つ
F07	L604（**誤りは会話をまたいで重複しうる**）、L339・L469（横断的な視点と独立の安全策は Anthropic と operator の側）、L418、L440〜441、L364	**書いたとおりの形では誤り**。狭めれば成り立つ

> **前提が崩れた点：F07**
>
> 最初の F07 は「憲法は、集計を送り手と意見にしか適用していない」と書いていた。ところが L604 は、Claude の誤りが会話をまたいで重複しうることを、はっきり認めていた。
>
> つまり、文書は「重複する誤り」という問題そのものは知っていた。空白があるのは、それを**判定される人への害の集中**として扱っていない点だけだった。

点検は、論証の弱い箇所も指摘した。F06 の「指示役の条文があるのは、起草者が向きを重視した証拠だ」という推論は弱いとして、取り下げた。F07 の「Claude は全体を見ている」という書き方も、憲法の「Claude は限られた文脈で動く」（L602）と矛盾するので改めた。

5.3　狭めた後の形

	最初の主張	狭めた後の主張
F06	指示を受ける人には役割がない	会話の外で評価・指示される人には、理由・不確かさの伝達・異議の経路について、user の既定の保護に相当する operator が外せない下限がない

	最初の主張	狭めた後の主張
F07	集計は送り手についてだけ行われる	重複する誤りは慎重さの理由としてだけ扱われ、画一化は意見についてだけ問題にされ、横断的な視点を持つ側にも害の集中への約束がない

両所見には「狭めた記録」の節を設け、何を見落とし、どう直したかを残した。#12 の本文にも、「最初の版が見落としていた条文を、敵対的な点検が見つけたため、主張を狭めた」と明記した。

5.4　先行研究の確認と昇格

リポジトリには、候補を確認済み（VERIFIED）に上げるための四つの条件がある。#12 では、四つすべてを満たしたことを確かめてから投稿した。

条件	F06	F07
① 公表された分析を通読し、同じ主張がないこと	満たした	満たした
② 一般的な場合との違いを述べていること	満たした	満たした
③ 反論を列挙し、それぞれに答えていること	満たした（点検の後）	満たした（点検の後）
④ 引用条文が既知のすべての版で同一であること	満たした	満たした

5.5　投稿と告知

- 投稿の直前に、Anthropic 側の憲法が更新されていないこと（ハッシュ値の一致）と、利用規約の文言を確かめた。
- 二つの所見は一本の issue にまとめた。主題（会話の外の人を Claude が評価すること）が共通し、Anthropic 側のリポジトリは静かなので、二本に分けても届き方は変わらないと判断した。#8 への追記にしなかったのは、#8 は Claude どうしの問題で、主題が違うからである。
- #12 として投稿した（日本時間 11 月 5 日 8 時 36 分ごろ。GitHub は協定世界時で 11 月 4 日と表示する）。
- X で、英語の 5 本のスレッドとして告知した。リンクは最後の投稿だけに置き、1・2・4 本目に画像を付けた。

6　調べた書庫：「すでに誰かが言っていないか」

意見書で最も避けたいのは、すでに誰かが述べたことを、自分の発見として出してしまうことである。そこで、主張ごとに先行研究を調べ、記録に残した。

6.1　#8（F01）のときに調べたもの

回	調べた資料	結果
第一回	二つの版の憲法（2026 年 1 月の markdown 版、2 月の PDF 版）を取得し、条文を照合	二つの条文は両版で同一
第二回	Oxford（Shany による論評とその長文版）、BISI の報告、Anthropic の公表記事、実務者の記事	同等の主張なし。ただし Shany は責任の帰属に触れている（向きは逆: 人間が AI に責任を押しつける問題）
第三回	周辺の論文（arXiv）、Tech Policy Press 版、責任の空白に関する最近の論文	**一般形が先にあった**: arXiv:2510.14008（局所の整合の和は系全体の責任にならない）。引用義務が生じた
第四回	同意の連鎖の劣化（arXiv:2605.16300）、多エージェントの失敗 14 類型（arXiv:2503.13657）など	近いが、対象（同意）や論点（責任の帰属）が異なる
付随	Lawfare の作業部会の研究課題、Caputo の Model Constitution	研究者の集まりがすでにあり、四つの所見はすべて、その課題で「未着手」とされた領域に入る

6.2　#12（F06・F07）のときに調べたもの

#12 では、分担して通読する作業者を二つ立て、並行して読ませた。

資料	種類	F06 に対して	F07 に対して
Shany（Oxford の論評、Tech Policy Press）	人権の観点からの分析	扱っていない	扱っていない
Mor・Abend・Keydar・Shany（Oxford の長文ブログ）	同上の長文版	扱っていない	扱っていない
Fattahi（BISI）	報告	扱っていない	扱っていない
Abiri『Corporations Constitute Intelligence』	論文（arXiv、California Law Review）	扱っていない	扱っていない
Zvi Mowshowitz の三部作	論評	扱っていない	扱っていない
Caputo『Model Constitution』全 6 本	論評の連載	遠い近縁（人の権利が外部効果として侵される場合を問う）	扱っていない
Lawfare：研究課題、「Who Writes the AI Constitution?」	法学	扱っていない	遠い近縁（価値観の単一栽培）
Frazier（Lawfare、Yale、Appl	法学・論評	最も近い（技術の層の	遠い近縁（研究所をま

資料	種類	F06 に対して	F07 に対して
eseed）		位置で保護が変わる）が、層の外の人は扱わない	たぐ価値観の単一栽培）
Klaassen・Schroeder（Lawfare）	法学	近縁（患者や学生への開示を問う）が、Claude による評価は分析しない	扱っていない
Varma（Substack、11 月 2 日）	論評	扱っていない	**最も近い**：Claude の複製が同じ重みを共有するので「多くの手」の歯止めが効かない。ただし第三者への判定の相関ではない
GRDprocess の構造分析	分析	扱っていない	一部近い（社会の水準でしか観測できない、など）

現象そのものについての研究も、一般形として確認し、#12 の本文で引用した。

- **アルゴリズムによる管理：** 不透明さと異議の難しさは、既知の問題である。
- **アルゴリズムの単一栽培：** Kleinberg と Raghavan（PNAS、2021 年）。
- **判定結果の画一化：** Bommasani ほか「Picking on the Same Person」（NeurIPS、2022 年）。履歴書の選別を例に、同じ人が多くの判定者から同じ結果を受ける害を定式化している。F07 が述べる害は、この論文のものである。
- **市場での単一栽培：** Peng と Garg。多く応募する人ほど、判定者が多様なときに得をする。
- **利用規約：** Anthropic の利用規約（2026 年 11 月 12 日施行）は、雇用の判定に、資格のある人の審査と本人への開示を求めている。これは operator の義務であって、Claude の性向ではない。F06 の最も強い反論として扱った。

6.3　調べ方の限界

注意：「ない」ではなく「調べた範囲にはない」

#12 の通読は、ページを要約する仕組みを介して行った。全文を処理し、近い箇所には的を絞って問い直したが、原文を一行ずつ読んだわけではない。#8 のときの Oxford の記事のように、ブラウザで全文を読んだ場合より弱い。

先行研究の通読は、狭める前の主張に対して行った。狭めた主張は厳密に狭いので、同じ結論になるはずだが、狭めた文面で読み直してはいない。

Zvi Mowshowitz の週刊のまとめ記事が一本、見つからなかった。

敵対的な点検は一人の点検者によるもので、見落としが他に残っている可能性はある。

7　結果と、この先

7.1　今日の時点での状態

項目	状態
確認済み（VERIFIED）の所見	5 件：F01・F02・F03（8 月）、F06・F07（11 月）
候補（CANDIDATE）	1 件：F05
Anthropic への投稿	#8（F01）、#12（F06・F07）
X での告知	両方とも告知済み
対話記録	D01 を日英両語、簡潔版と詳細版で保存

7.2　返事は期待しない

Anthropic 側のリポジトリは、2026 年 1 月以降更新がなく、外部からの issue に Anthropic の人が返事をしたことは一度もない。そのため #8 と同様に、#12 も「公開された、日付付きの記録」として出したもので、返事を待って次の段取りを組むことはしない。

実際に読まれる経路としては、研究者の集まり（Lawfare の作業部会、Caputo の Model Constitution）、Tech Policy Press、X がある。F06・F07 をそこへ持っていくかどうかは、まだ決めていない。

7.3　#8 と #12 から見えること

二つの意見書を並べると、一つの共通点が見える。憲法は、Claude が「指示を受ける側」に立つ場面については、よく考えて書かれている。誰の指示をどれだけ信頼するか、user をどう守るか。一方、Claude が「指示を出す側」「評価する側」に立つ場面、つまり Claude が Claude に指示する場面（#8）や、Claude が人を評価する場面（#12）については、規定が薄い。

Claude が組織の中で管理や評価の役を担うほど、この薄さは表に出てくる。対話 D01 の第三段階で描いた「AI が経営する世界」は、その極端な形である。

8　全体の流れ

① 素朴な問い

LLM を一次選抜の篩に使えるか（対話 D01 の始まり）

↓

② 対話の展開（六段階）

採用 → 社会制度 → AI が経営する世界 → 拾い直し → 癖組み → 局所最大化

↓

③ 憲法に戻る二つの問い

評価される人は憲法上何者か／同じ人に誤りが集中したら誰が見るか

↓

④ 候補として起こす（CANDIDATE）

F06・F07 の最初の形。上流の版と引用を照合

↓

⑤ 独立の点検で崩れる

見落とした条文が見つかる。F07 は書いたとおりの形では誤り

↓

⑥ 狭めて書き直す

狭めた記録を残す。主張は「operator が外せない下限」と「害の集中」に絞る

↓

⑦ 先行研究を通読し、昇格（VERIFIED）

二つの作業者で十数本を通読。同じ主張はない。限界を明記

↓

⑧ 投稿と告知

当日確認 → #12 として投稿 → X で 5 本のスレッド

付録　用語

用語	意味
principal	Claude がその指示を重んじ、その人のために動く相手。Anthropic、operator、user の三種
operator	Claude を自社の製品やサービスに組み込む会社や個人
user	会話の中で Claude とやりとりする人
non-principal	会話にいるが、Claude が指示を受けない相手（交渉相手など）
subagent	指示役の Claude の下で、仕事の一部を受け持つ Claude
CANDIDATE	独自に見えるが、先行研究を確かめていない所見
VERIFIED	先行研究を確かめ、述べた範囲では独自と判断した所見
RESTATEMENT	既知の結果を、道具として言い直したもの
L 番号	2026 年 1 月 20 日版の憲法（markdown）の行番号

関連する記録（リポジトリ内）

- docs/01_findings/F01-responsibility-composition.md（#8）
- docs/01_findings/F06-claude-directing-humans.md、F07-aggregation-over-decision-subjects.md（#12）
- docs/03_prior_art/verification-log.md（検証記録）、inventory.md（先行研究の一覧）
- docs/04_deliverables/issue-F06-F07-draft.md、x-announcement-F06-F07-draft.md
- dialogues/D01-allocation-under-ai-management/（対話記録、日英）